

Ćwiczenia — Formaty i źródła danych

Obróbka danych

1. Ćwiczenie 1: Kodowanie znaków

Pliki: `pracownicy_utf8.csv`, `pracownicy_cp1250.csv`

1.1. Zadania

1. Wczytaj każdy plików bez podawania parametru `encoding`. Który się wczytuje poprawnie? Który wyrzuca błąd? Dlaczego?
2. Wczytaj plik CP1250 z parametrem `encoding="utf-8"` i na odwrót — plik UTF-8 z `encoding="cp1250"`. Co dostajesz w każdym przypadku? Zwróć uwagę na różnicę między błędem (`UnicodeDecodeError`) a cichym zepsuciem danych (`mojibake`).
3. Zapisz plik z kodowaniem CP1250 jako jeden plik w kodowaniu UTF-8.

2. Ćwiczenie 2: Brudny CSV

Plik: `klienci.csv`

Plik zawiera wszystkie typowe pułapki naraz: kodowanie CP1250, średnik jako separator, przecinek jako separator dziesiętny, kody pocztowe z wiodącymi zerami, daty w formacie DD.MM.YYYY, brakujące wartości zapisane jako `brak`, `-`, `?`, oraz jedno pole adresu zawierające średnik w cudzysłowie.

2.1. Zadania

1. Spróbuj wczytać plik najprościej: `pd.read_csv("klienci.csv")`. Co się dzieje?
2. Napraw po kolei: kodowanie, separator, separator dziesiętny, format daty, brakujące wartości, typ kolumny `kod_pocztowy`.
3. Sprawdź `df.dtypes` — czy wszystkie kolumny mają właściwe typy?
4. Policz, ilu klientów jest z Łodzi i jaki jest ich średni dochód.
5. Zapisz oczyszczony DataFrame jako Parquet i porównaj rozmiar pliku z oryginalnym CSV.

3. Ćwiczenie 3: Pobieranie danych z API NBP

Bez plików — dane pobierasz z internetu. API Narodowego Banku Polskiego jest darmowe i nie wymaga klucza. Dokumentacja: <https://api.nbp.pl/>

Endpoint: `https://api.nbp.pl/api/exchangerates/rates/A/EUR/last/30/`

3.1. Zadania

1. Pobierz notowania EUR z ostatnich 30 dni używając biblioteki `requests`.

2. Wyświetl strukturę odpowiedzi JSON — co jest w środku?
3. Zamień odpowiedź na DataFrame (użyj `pd.json_normalize` albo zbuduj DataFrame ręcznie z pola `rates`).
4. Ustaw kolumnę `effectiveDate` jako indeks daty, narysuj wykres kursu w czasie.
5. Pobierz analogiczne dane dla USD i GBP. Połącz wszystko w jeden DataFrame i narysuj trzy linie na jednym wykresie.
6. Zapisz wynik jako Parquet.
7. **Dodatkowe:** pobierz dane historyczne z całego 2024 roku i znajdź, kiedy EUR był najdroższy.

4. Ćwiczenie 4: Benchmark formatów

Plik: pomiary.csv (ok. 91 tys. wierszy, ~6 MB)

Symulacja danych o jakości powietrza: 50 stacji $\times$ 5 lat pomiarów dziennych $\times$ 7 parametrów (PM2.5, PM10, NO2, O3, temperatura, wilgotność, prędkość wiatru).

4.1. Zadania

1. Wczytaj CSV do DataFrame.
2. Zapisz ten sam DataFrame jako: JSON, Parquet, HDF5, Pickle.
3. Zmierz rozmiary wszystkich plików na dysku. Zrób wykres słupkowy.
4. Zmierz czas wczytywania każdego formatu (`%timeit` albo `time.perf_counter`). Zrób drugi wykres.
5. Wczytaj tylko 2 kolumny z Parquet (`columns=["date", "pm25"]`) — porównaj czas z wczytaniem wszystkich kolumn.
6. **Wnioski:** który format byś wybrał do długoterminowego przechowywania? Do szybkich analiz?

5. Ćwiczenie 5: SQLite i pandas

Plik: sklep.db

Baza zawiera trzy tabele: `klienci` (200 rekordów), `produkty` (15 rekordów), `zamowienia` (1000 rekordów).

5.1. Zadania

1. Podłącz się do bazy i wylistuj dostępne tabele (zapytanie do `sqlite_master`).
2. Wczytaj każdą z trzech tabel jako oddzielny DataFrame. Sprawdź rozmiary i typy kolumn.
3. Napisz zapytanie SQL, które zwraca 10 klientów z największą liczbą zamówień.

Dodatkowe:

1. Użyj `chunksize` w `pd.read_sql`, żeby wczytać tabelę `zamowienia` porcjami po 100 rekordów.
2. Napisz zapytanie SQL, które zwraca sumaryczną wartość sprzedaży per kategoria produktu.

3. Zrób to samo w pandas. Porównaj kod pod względem czytelności.